

Framework Qualité des Données

10 dimensions pour évaluer et piloter la fiabilité de vos données — dataSAI, data Solutions and Artificial Intelligence

Dimension	Définition	Indicateur	Interprétation
■ Exactitude	Les données correspondent-elles à la réalité ? Un client marqué « actif » alors qu'il est parti depuis 6 mois, c'est une donnée inexacte — et ça fausse analyses et modèles sans qu'on s'en rende compte.	Taux d'exactitude = (enregistrements corrects ÷ total) × 100	> 95 % — fiable 90–95 % — surveiller < 90 % — audit requis
■ Exhaustivité	Toutes les données nécessaires sont-elles présentes ? Des emails manquants dans une base marketing, c'est une campagne qui rate une partie de son audience. Les angles morts mènent à de mauvaises décisions.	Taux de complétude = (champs remplis ÷ champs attendus) × 100	> 98 % — optimal < 95 % — biais significatif sur les champs critiques
■ Cohérence	Les données sont-elles homogènes entre systèmes ? Deux outils affichant des statuts différents pour un même client, c'est une perte de confiance immédiate pour les équipes et les analyses.	Taux d'incohérence = (enregistrements en conflit ÷ total) × 100	< 2 % — acceptable > 5 % — référentiel unique requis
■ Actualité	Les données sont-elles suffisamment récentes ? Un stock mis à jour une fois par semaine pour un e-commerce, c'est une source d'erreurs à chaque commande.	Âge moyen = Σ (date actuelle – date MAJ) ÷ nb d'enregistrements	< 24h — dashboard opérationnel ~ 30j — CRM > 90j — données obsolètes
■ Pertinence	Les données collectées sont-elles réellement exploitées ? Collecter 50 champs dont seulement 10 sont utiles, c'est de la pollution data qui alourdit les systèmes et dilue l'attention.	Taux d'utilisation = (champs exploités ÷ champs collectés) × 100	> 70 % — efficient < 50 % — problème de gouvernance
■ Validité	Les données respectent-elles les formats et règles métier ? Un email sans « @ » ou une date invalide passe inaperçu — jusqu'au moment où ça bloque un processus entier.	Taux de validité = (enregistrements valides ÷ total) × 100	> 99 % — conforme < 97 % — revue des règles requise

Dimension	Définition	Indicateur	Interprétation
■ Unicité	Chaque entité est-elle représentée une seule fois ? Un client présent trois fois dans un CRM, c'est trois fois les efforts marketing pour la même personne — et une vision client faussée.	Taux de duplication = (doublons détectés ÷ total) × 100	< 1 % — propre > 3 % — dédoublonnage urgent
■ Intégrité	Les relations entre données sont-elles respectées ? Une commande liée à un client inexistant dans la base, c'est une incohérence structurelle aux conséquences opérationnelles réelles.	Taux d'intégrité = (liens valides ÷ total des liens) × 100	100 % — intègre < 98 % — revue architecture requise
■ Disponibilité	Les données sont-elles accessibles quand on en a besoin ? Des données indisponibles lors d'un reporting critique, c'est une décision prise à l'aveugle — ou reportée.	Taux de disponibilité = (temps accessible ÷ temps total) × 100	> 99,5 % — opérationnel < 99 % — SLA à revoir
■ Traçabilité	Peut-on retracer l'origine et les transformations d'une donnée ? Quand personne ne sait d'où vient un chiffre, la confiance dans les données s'effondre — et la conformité avec elle.	Taux de couverture lineage = (flux documentés ÷ flux totaux) × 100	> 90 % — auditable < 70 % — risque conformité (RGPD, SOX...)